






H.IAAC | HUB DE INTELIGÊNCIA
ARTIFICIAL E ARQUITETURAS
COGNITIVAS



Andamento Pesquisa Fed HAR





Metodologia

Metodologia

Datasets Utilizados

- **DAGHAR:** 6 datasets de HAR (**KuHar**, **MotionSense**, **UCI**, **WINSDDM**, **RealWorld_thigh**, **RealWorld_waist**).
- **Pré-treino Federado:**
 - **Cenário cross device:**
 - **KuHar** → **57 usuários**,
 - **MotionSense** → **17 usuários**,
 - **RealWorld** → **10 usuários**,
 - **UCI** → **21 usuários**,
 - **WISDDM** → **36 usuários**.
 - **Parcial** = **84 clientes**.

Metodologia

Componentes do Pipeline

- **Encoders:**
 - ResNet-SE-5
 - CNN
 - RNN
 - TS-TCC.
- **Métodos de SSL:**
 - **LFR** (*Learning From Randomness*),
 - **TF-C** (*Time-Frequency Consistency*).
- **Agregação:**
 - **FedAvg**.

Metodologia


Experimentos

- **1º Experimento.**

Validação Centralizada: Supervisionado, LFR e TF-C, aplicados nos 4 encoders sobre o DAGHAR. (Replicação do Benchmark + Análise Transfer Domain)

- **2º Experimento (FUTURO).**

SSL Federado: pré-treino SSL dentro da federação + fine tuning federado.




Resultados Preliminares

Resultados Preliminares

Centralizado Supervisionado

- 112 modelos: 4 encoders x 4 seeds x (6 datasets + dataset combinado)

- Conclusão:
“Domínios
Diferentes
Degradam
Desempenho.”



Resultados Preliminares


Centralizado Self-Supervised

- **Pré-treino:**
 - **224 modelos: 4 encoders x 4 seeds x (6 datasets + dataset combinado) x 2 SSL.**
- **Linear readout + Fine Tuning:**
 - **Avaliando em Domínio Próprio + Cross Domain (5 casos).**
 - **4 regimes de avaliação: 1, 10, 100 samples per class e 100% dos dados.**
- **Total = $224 \times 2 \times 6 \times 4 = 10.752$ testes**

Resultados Preliminares

TF-C vs LFR vs Linear Readout

Eficiência de dados: LFR vs TF-C sob linear readout (média encoders x seeds)




- TF-C perde para o LFR no Linear Readout com 1-shot mas TF-C recupera para outros regimes

Resultados Preliminares

LFR

LFR vs SL — acurácia in-domain por regime de rótulos




- LFR tem ganho real apenas com a RNN


Resultados Preliminares

TF-C

TF-C vs SL — acurácia in-domain por regime de rótulos




- TF-C apresenta ganhos reais em todos cenários.




Estendendo o Benchmark

Resultados Preliminares

SL vs pré-treino SSL + finetune — 100% dos rótulos
(média de 4 encoders × 4 seeds; SSL em protocolo finetune)



Eficiência de dados: SL vs SSL-finetune (média encoders × seeds)




- TF-C (+) e LFR (-) ajudam a mitigar a degradação do modelo em outros domínios.


Resultados Preliminares

TF-C e LFR: spoiler da federação?

LFR: pré-treino multi-domínio ~neutro no próprio domínio
(finetune, 100%; média de 4 encoders x 4 seeds; erro = dp entre seeds)




TF-C: pré-treinar no corpus multi-domínio não degrada o especialista
(finetune, 100%; média de 4 encoders x 4 seeds; erro = dp entre seeds)



- A queda do cenário combined vem dos rótulos misturados no finetune.
- Motiva FedSSL → Pré-treino com todos domínios + fine tuning local?



Resultados Preliminares

Transfer out-domain fonte → alvo — acurácia (%), finetune @ 100% dos rótulos
(média ± dp entre seeds; 4 encoders × 4 seeds; diagonal in-domain omitida)



Resultados Preliminares

Ganho do SSL no transfer out-domain — $\Delta(\text{SSL} - \text{SL})$ fonte $\rightarrow$ alvo, finetune @ 100%
(azul = SSL melhor; média $\pm$ dp entre seeds; 4 encoders $\times$ 4 seeds; diagonal omitida)



Resultados Preliminares

Pré-treino multi-dataset vs. especialista

Acurácia (%), média $\pm$ dp entre seeds. **Negrito** = melhor por linha; – = n/a.

Método	Alvo	Acurácia (%)			Δ (pp)		
		Especialista	Comb→alvo	Combined	vs. SL	Pré-treino multi	Rótulos mist.
SL	KuHar	64,36 $\pm$ 2,69	–	62,21 $\pm$ 1,81	0,00	–	–2,15
	MotionSense	81,22 $\pm$ 1,98	–	76,46 $\pm$ 3,33	0,00	–	–4,75
	RealWorld_thigh	69,76 $\pm$ 0,56	–	67,98 $\pm$ 1,24	0,00	–	–1,78
	RealWorld_waist	71,15 $\pm$ 0,70	–	68,85 $\pm$ 1,28	0,00	–	–2,30
	UCI	89,91 $\pm$ 0,21	–	77,73 $\pm$ 2,73	0,00	–	–12,18
	WISDM	83,12 $\pm$ 0,60	–	74,44 $\pm$ 2,00	0,00	–	–8,67
	<i>Média</i>	76,59 $\pm$ 0,76	–	71,28 $\pm$ 1,80	0,00	–	–5,31
LFR	KuHar	62,06 $\pm$ 7,37	58,54 $\pm$ 3,70	61,72 $\pm$ 2,13	–2,29	–3,52	+3,17
	MotionSense	85,80 $\pm$ 1,16	86,05 $\pm$ 1,59	80,44 $\pm$ 1,08	+4,58	+0,24	–5,61
	RealWorld_thigh	69,75 $\pm$ 0,34	68,23 $\pm$ 0,59	69,96 $\pm$ 2,70	–0,01	–1,53	+1,73
	RealWorld_waist	72,04 $\pm$ 1,85	72,16 $\pm$ 0,75	70,50 $\pm$ 1,68	+0,89	+0,11	–1,65
	UCI	91,46 $\pm$ 0,39	91,91 $\pm$ 0,41	80,20 $\pm$ 3,26	+1,54	+0,46	–11,72
	WISDM	86,03 $\pm$ 0,55	86,08 $\pm$ 0,62	76,73 $\pm$ 2,64	+2,92	+0,05	–9,34
	<i>Média</i>	77,86 $\pm$ 1,27	77,16 $\pm$ 0,76	73,26 $\pm$ 1,92	+1,27	–0,70	–3,90
TF-C	KuHar	75,49 $\pm$ 0,41	77,39 $\pm$ 2,00	73,19 $\pm$ 2,09	+11,13	+1,90	–4,20
	MotionSense	89,89 $\pm$ 1,98	90,92 $\pm$ 1,05	86,81 $\pm$ 1,38	+8,67	+1,03	–4,11
	RealWorld_thigh	72,83 $\pm$ 3,13	74,03 $\pm$ 1,00	76,82 $\pm$ 0,87	+3,07	+1,20	+2,80
	RealWorld_waist	76,30 $\pm$ 2,21	75,71 $\pm$ 0,99	75,44 $\pm$ 0,57	+5,15	–0,59	–0,27
	UCI	94,72 $\pm$ 0,16	92,94 $\pm$ 0,84	87,47 $\pm$ 1,08	+4,80	–1,78	–5,47
	WISDM	87,72 $\pm$ 0,40	88,84 $\pm$ 0,40	81,52 $\pm$ 0,42	+4,60	+1,13	–7,32
	<i>Média</i>	82,82 $\pm$ 0,38	83,31 $\pm$ 0,18	80,21 $\pm$ 0,48	+6,24	+0,48	–3,10

Resultados Preliminares

Resumo dos métodos: SL vs. SSL

Acurácia e F1-macro (%): média $\pm$ dp entre seeds (2 casas). **Negrito** = melhor por coluna.


Método	Acurácia (%)			F1-macro (%)			Δ Acc vs. SL (pp)		
	Comb.	Cross	In-dom.	Comb.	Cross	In-dom.	Comb.	Cross	In-dom.
SL (from scratch)	71,28 $\pm$ 1,80	46,26 $\pm$ 0,30	76,59 $\pm$ 0,76	64,45 $\pm$ 2,50	36,52 $\pm$ 0,56	73,42 $\pm$ 1,12	0,00	0,00	0,00
LFR (linear)	71,99 $\pm$ 0,33	45,00 $\pm$ 0,68	73,74 $\pm$ 0,38	65,69 $\pm$ 0,64	35,81 $\pm$ 0,46	71,54 $\pm$ 0,34	+0,71	-1,26	-2,85
LFR (fine-tune)	73,26 $\pm$ 1,92	46,46 $\pm$ 1,30	77,86 $\pm$ 1,27	66,97 $\pm$ 2,27	36,72 $\pm$ 1,18	75,42 $\pm$ 1,57	+1,98	+0,21	+1,27
TF-C (linear)	68,82 $\pm$ 1,10	46,51 $\pm$ 0,36	71,76 $\pm$ 1,05	63,04 $\pm$ 1,14	37,49 $\pm$ 0,52	69,50 $\pm$ 1,39	-2,46	+0,25	-4,83
TF-C (fine-tune)	80,21 $\pm$ 0,48	49,28 $\pm$ 0,30	82,82 $\pm$ 0,38	74,40 $\pm$ 0,33	40,62 $\pm$ 0,45	81,74 $\pm$ 0,43	+8,93	+3,02	+6,24

Resultados Preliminares

Eficiência de dados — full fine-tuning

Acurácia (%), média $\pm$ dp entre seeds, por regime de rótulos. **Negrito** = melhor por coluna; Δ = ganho vs. SL (pp).


Cenário	Método	Acurácia (%)			
		1-shot	10-shot	100-shot	100%
In-domain	SL	41,87 $\pm$ 2,51	58,20 $\pm$ 1,14	74,00 $\pm$ 1,57	76,59 $\pm$ 0,76
	LFR	43,10 $\pm$ 4,15	62,39 $\pm$ 1,42	74,48 $\pm$ 1,25	77,86 $\pm$ 1,27
	TF-C	44,69 $\pm$ 4,36	70,36 $\pm$ 0,73	79,87 $\pm$ 0,58	82,82 $\pm$ 0,38
	Δ LFR–SL	+1,23	+4,18	+0,48	+1,27
	Δ TF-C–SL	+2,82	+12,15	+5,87	+6,24
Cross-domain	SL	32,09 $\pm$ 2,06	39,88 $\pm$ 0,92	44,92 $\pm$ 0,66	46,26 $\pm$ 0,30
	LFR	33,21 $\pm$ 3,05	41,95 $\pm$ 0,97	45,59 $\pm$ 0,66	46,46 $\pm$ 1,30
	TF-C	33,18 $\pm$ 2,65	45,41 $\pm$ 0,56	48,60 $\pm$ 0,72	49,28 $\pm$ 0,30
	Δ LFR–SL	+1,11	+2,07	+0,67	+0,21
	Δ TF-C–SL	+1,08	+5,54	+3,68	+3,02




Próximos Passos

Próximos Passos


- Refino das Análises
- Baseline Federado Cross Device;
- Pré-treino **Federado**:
 - **LFR e TF-C**;
 - **CNN, RNN, ResNet e TS-TCC**;
 - **Datasets**:
 - **MotionSense** → **17 usuários**,
 - **UCI** → **21 usuários**,
 - **WISDM** → **36 usuários**.
 - **Parcial = 64 clientes**.




ARQUITETURAS
COGNITIVAS




APRENDIZADO EM
ARQUITETURAS COGNITIVAS




APRENDIZADO
DISTRIBUÍDO




REPRESENTAÇÃO DE
CONHECIMENTO




PROCESSAMENTO DE
LINGUAGEM NATURAL




IA PARA
FINANÇAS



IA PARA
MARKETING



GESTÃO DA
PESQUISA



Título

Subtítulo

Título

Subtítulo

Teste

Teste 2

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Sed laoreet placerat libero in auctor. Pellentesque condimentum dui non nibh varius, id mattis velit dignissim. Fusce tortor dui, euismod eget ligula id, posuere malesuada ligula. Fusce convallis nulla id pretium tempor. Cras eu pulvinar felis, a vulputate libero. Donec volutpat in tortor non luctus. Sed faucibus nulla nec viverra sodales. Integer elementum mollis venenatis. Morbi maximus consequat tortor, quis pharetra nunc condimentum at. Pellentesque lobortis varius ligula in gravida. Maecenas mattis leo commodo, euismod augue et, laoreet augue.

Teste

Subtítulo longo Lorem ipsum dolor sit amet, consectetur adipiscing

Teste 2

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Sed laoreet placerat libero in auctor. Pellentesque condimentum dui non nibh varius, id mattis velit dignissim. Fusce tortor dui, euismod eget ligula id, posuere malesuada ligula. Fusce convallis nulla id pretium tempor. Cras eu pulvinar felis, a vulputate libero. Donec volutpat in tortor non luctus. Sed faucibus nulla nec viverra sodales. Integer elementum mollis venenatis. Morbi maximus consequat tortor, quis pharetra nunc condimentum at. Pellentesque lobortis varius ligula in gravida. Maecenas mattis leo commodo, euismod augue et, laoreet augue.

