

Aprendizado Auto-Supervisionado Federado para Reconhecimento de Atividades Humanas sob Heterogeneidade de Domínio

Candidato(a):	Miguel Francisco Bossoni Barreto
Orientador(a):	Allan M. de Souza
Nível:	Mestrado
Duração do plano:	01/06/2026 a 01/08/2026 (3 meses)
Entregável:	1 — referente ao 1º mês (01/06/2026 a 01/07/2026)
Palavras-chave:	Aprendizado Federado, Aprendizado Auto-Supervisionado, Séries Temporais, Reconhecimento de Atividades Humanas.

Relatório Referente ao Entregável 1

O quadro abaixo reproduz a linha do cronograma do plano de trabalho correspondente ao primeiro mês. Este relatório cobre exclusivamente as atividades ali previstas.

Mês	Atividades	Entregável mensal
1	• Revisão de literatura sobre SSL para séries temporais e estratégias de mitigação de heterogeneidade em FL. • Implementação e validação centralizada das técnicas de SSL selecionadas (LFR e TF-C) sobre os datasets do DAGHAR, utilizando os três encoders considerados. • Avaliação das representações aprendidas via linear readout em cada dataset. • Definição final dos hiperparâmetros e do protocolo de avaliação a ser adotado nos cenários federados.	• Relatório técnico com os resultados do Experimento 1 (validação centralizada do SSL) e justificativa das escolhas metodológicas para os experimentos federados.

1. Introdução e contextualização

O Reconhecimento de Atividades Humanas (HAR) a partir de sensores inerciais é uma tarefa de classificação de séries temporais cujo desempenho depende de grandes volumes de dados anotados, tipicamente coletados em dispositivos pessoais. O Aprendizado Federado (FL) permite treinar modelos sobre esses dados sem centralizá-los, mas em cenários reais de HAR cada cliente coleta sob condições distintas — posição do sensor no corpo, dispositivo, taxa de amostragem e protocolo de coleta —, o que produz heterogeneidade de domínio entre clientes e degrada o modelo agregado.

A hipótese central do plano é que representações aprendidas por Aprendizado Auto-Supervisionado (SSL), por não dependerem dos rótulos específicos de cada domínio,

sejam mais robustas a variações nas distribuições marginais dos dados e produzam federações mais estáveis do que a inicialização aleatória. O plano investiga duas técnicas de SSL para séries temporais — **LFR** (Learning from Randomness) e **TF-C** (Time-Frequency Consistency) — em três cenários experimentais, distribuídos ao longo de três meses.

Este primeiro entregável corresponde ao **Experimento 1**: a implementação e a validação **centralizada** das duas técnicas de SSL sobre o benchmark DAGHAR, cujo objetivo duplo é (i) verificar a correção das implementações e (ii) estabelecer a referência de desempenho em ambiente centralizado contra a qual os cenários federados dos meses 2 e 3 serão comparados. O relatório reporta ainda a revisão de literatura que fundamenta o desenho e a definição final dos hiperparâmetros e do protocolo de avaliação a ser adotado nas etapas federadas.

As seções seguem as quatro atividades previstas: a Seção 2 trata da revisão de literatura; as Seções 3 e 4, da implementação, validação centralizada e avaliação por linear readout; e a Seção 5, da definição dos hiperparâmetros e do protocolo de avaliação.

2. Revisão de literatura

2.1. Escopo e método do levantamento

A revisão foi conduzida em duas frentes complementares, correspondentes aos dois eixos do plano: (a) Aprendizado Auto-Supervisionado para séries temporais e (b) estratégias de mitigação de heterogeneidade entre clientes em Aprendizado Federado. O levantamento partiu de buscas estruturadas nas bases arXiv, IEEE Xplore, ACM DL e Springer, complementadas por *snowballing* de citações via Semantic Scholar e OpenAlex a partir dos dois artigos originais das técnicas selecionadas (TF-C e LFR).

Os trabalhos levantados foram organizados em três blocos temáticos — **A** (Aprendizado Federado), **B** (Aprendizado Auto-Supervisionado) e **C** (Aprendizado Auto-Supervisionado Federado) — e priorizados por dois critérios de corte: o trabalho é cobrado por um revisor da área, ou ele altera uma decisão de desenho da proposta. A seguir apresentam-se os principais trabalhos revisados, com suas contribuições e as limitações identificadas.

2.2. Bloco A — Aprendizado Federado e heterogeneidade entre clientes

- Communication-Efficient Learning of Deep Networks from Decentralized Data (FedAvg) — McMahan et al., 2017
 - Publicação: AISTATS
 - Tópicos: Aprendizado Federado
 - Contribuições:
 - Define o algoritmo FedAvg, agregador adotado como base neste trabalho.
 - Formaliza o compromisso entre rodadas de comunicação e computação local.
 - Apresenta a primeira caracterização empírica de dados non-IID em FL.
 - Limitações:
 - O non-IID estudado é sintético (partição por rótulo do MNIST/CIFAR), não heterogeneidade de domínio real.
 - Não trata de séries temporais nem de dados de sensores.

- Não considera pré-treino nem inicialização não-aleatória do modelo global.
- **FedBN: Federated Learning on Non-IID Features via Local Batch Normalization — Li et al., 2021**
 - Publicação: ICLR
 - Tópicos: Aprendizado Federado, Heterogeneidade
 - Contribuições:
 - Trata especificamente do *feature shift*, que é o tipo de heterogeneidade do nosso cenário (mesma tarefa, distribuições de entrada distintas).
 - Mostra que manter as camadas de normalização locais melhora a convergência sob heterogeneidade de features.
 - Solução de custo computacional praticamente nulo, aplicável como variante do FedAvg.
 - Limitações:
 - Avaliação restrita a imagens; não há evidência em séries temporais de sensores.
 - Não aborda pré-treino auto-supervisionado.
 - O mecanismo não é analisado sob escassez de rótulos.
- **Federated Optimization in Heterogeneous Networks (FedProx) — Li et al., 2020**
 - Publicação: MLSys
 - Tópicos: Aprendizado Federado, Heterogeneidade
 - Contribuições:
 - Termo proximal que limita a divergência entre modelo local e global.
 - Baseline de referência obrigatório em trabalhos de heterogeneidade em FL.
 - Trata também de heterogeneidade de sistemas (clientes com capacidades distintas).
 - Limitações:
 - Endereça heterogeneidade estatística de rótulos, não de domínio de entrada.
 - O ganho depende de calibração do coeficiente proximal.
 - Não interage com estratégias de pré-treino.
- **Rethinking the Starting Point: Collaborative Pre-Training for Federated Downstream Tasks (CoPreFL) — 2024**
 - Publicação: AAAI
 - Tópicos: Aprendizado Federado, Pré-treino
 - Contribuições:
 - Fundamenta diretamente o cenário do Experimento 2: pré-treino centralizado usado como inicialização de uma federação.
 - Evidencia que a qualidade da inicialização afeta a robustez da federação a clientes heterogêneos.
 - Limitações:
 - O pré-treino considerado é supervisionado, não auto-supervisionado.
 - Não avalia séries temporais.
 - Não mede custo de comunicação do pré-treino.

2.3. Bloco B — Aprendizado Auto-Supervisionado para séries temporais

- **Benchmarking Encoders and Self-Supervised Learning for Smartphone-Based Human Activity Recognition — da Luz et al., 2026**

- Publicação: IEEE Access
- Tópicos: SSL, Séries Temporais, HAR
- Contribuições:
 - Define o protocolo experimental, os encoders e os baselines reusados integralmente neste trabalho.
 - Compara técnicas de SSL para HAR sob regimes variáveis de rótulos, permitindo validação célula a célula da nossa reprodução.
 - Disponibiliza configurações completas, o que torna a replicação verificável.
- Limitações:
 - Inteiramente **centralizado**: não há qualquer conteúdo federado.
 - Não avalia corpora de pré-treino agregando múltiplos domínios.
 - Não mede custo de comunicação nem robustez a heterogeneidade entre clientes.
- Self-Supervised Contrastive Pre-Training for Time Series via Time-Frequency Consistency (TF-C) — Zhang et al., 2022
 - Publicação: NeurIPS
 - Tópicos: SSL, Séries Temporais
 - Contribuições:
 - Uma das duas técnicas adotadas: impõe consistência entre representações no domínio do tempo e da frequência.
 - Formula a perda contrastiva NT-Xent com termo de consistência tempo-frequência.
 - Demonstra transferência entre domínios distintos de séries temporais.
 - Limitações:
 - Nunca avaliado em ambiente federado (verificado no levantamento).
 - O backbone composto (duas cópias do encoder) dobra o número de parâmetros, o que tem implicação direta em custo de comunicação — aspecto não analisado pelo paper.
 - Não trata de heterogeneidade entre clientes.
- Self-Supervised Learning of Time Series Representation via Diverse Augmentation-Free Random Projectors (LFR) — Sui et al., 2024
 - Publicação: ICLR
 - Tópicos: SSL, Séries Temporais
 - Contribuições:
 - A segunda técnica adotada: dispensa augmentações, usando projetores aleatórios congelados como alvos de predição.
 - Seleção de alvos por DPP (*Determinantal Point Process*), garantindo diversidade entre projetores.
 - Por ser *augmentation-free*, elimina a dependência de augmentações específicas de domínio — propriedade potencialmente vantajosa sob heterogeneidade.
 - Limitações:
 - Também nunca avaliado em ambiente federado.
 - O custo de manter e sincronizar os projetores em cenário distribuído não é discutido.
 - Não há análise de sensibilidade ao tamanho do batch, relevante quando os dados são particionados entre clientes.
- DAGHAR: A Benchmark for Domain Adaptation and Generalization in Smartphone-Based Human Activity Recognition — Napoli et al., 2024

- Publicação: Scientific Data
- Tópicos: HAR, Séries Temporais, Datasets
- Contribuições:
 - Fornece a coleção de dados usada em todo o plano, com seis datasets padronizados sob uma mesma taxa de amostragem e um mesmo conjunto de classes.
 - Remove vieses triviais entre datasets, isolando a heterogeneidade de domínio como variável de interesse.
 - Splits disjuntos por usuário, o que permite particionamento sem vazamento.
- Limitações:
 - Concebido para avaliação centralizada; não define protocolo federado.
 - Todos os datasets são de sensores de smartphone, limitando a generalização a outras modalidades.
 - Não fornece baselines auto-supervisionados.
- Self-supervised Learning for Accelerometer-based Human Activity Recognition: A Survey — Logacjov, 2024
 - Publicação: ACM IMWUT 8(4):149
 - Tópicos: SSL, HAR
 - Contribuições:
 - Taxonomia abrangente das famílias de SSL aplicadas a acelerometria.
 - Sistematiza os protocolos de avaliação usados na área (linear probe vs. fine-tuning, regimes de rótulos).
 - Limitações:
 - Cobertura exclusivamente **centralizada** — o survey não trata de Aprendizado Federado.
 - Foco em acelerômetro, com menor atenção a sinais multimodais acelerômetro+giroscópio.
 - Não discute o efeito de agregação de pesos sobre representações auto-supervisionadas.
- Impact of Pre-training Datasets on Self-Supervised Learning for Human Activity Recognition — Rodrigues da Silva et al., 2024
 - Publicação: BRACIS
 - Tópicos: SSL, HAR, Pré-treino
 - Contribuições:
 - Origem do desenho *pré-treino em corpus agregado* → *especialização no alvo* adotado no nosso Experimento 1.
 - Mostra que a composição do corpus de pré-treino altera materialmente a qualidade da representação.
 - Limitações:
 - Restrito a uma técnica de SSL (CPC).
 - Centralizado; não considera que o corpus agregado é justamente o que o FL não pode formar.
 - Não avalia regimes de escassez de rótulos no downstream.
- Realistic Evaluation of Deep Semi-Supervised Learning Algorithms — Oliver et al., 2018
 - Publicação: NeurIPS
 - Tópicos: Avaliação, Aprendizado Semi-Supervisionado
 - Contribuições:



- Referência canônica sobre os vieses de avaliação em regimes de poucos rótulos; motivou a auditoria do nosso protocolo (Seção 5.3).
- Quantifica, via desigualdade de Hoeffding, o tamanho de conjunto de validação necessário para seleção de modelo confiável.
- Exige baseline supervisionado com o mesmo orçamento de ajuste e baseline de transferência — ambos incorporados ao nosso desenho.
- Limitações:
 - Anterior à geração atual de métodos contrastivos; exemplos em visão computacional.
 - Não trata de séries temporais nem de cenários federados.
 - Aponta o problema sem oferecer protocolo substituto consensual.

2.4. Bloco C — Aprendizado Auto-Supervisionado Federado

- Divergence-aware Federated Self-Supervised Learning (FedU / FedEMA) — Zhuang et al., 2022
 - Publicação: ICLR
 - Tópicos: SSL Federado
 - Contribuições:
 - Framework de referência para métodos siameses em ambiente federado.
 - Identifica o *dilema do preditor*: quais módulos agregar e quais reter localmente — decisão que se aplica diretamente aos projetores do LFR.
 - Mostra que reter parte dos módulos localmente melhora o resultado sob heterogeneidade.
 - Limitações:
 - Avaliado em imagens (BYOL/SimSiam), não em séries temporais.
 - A heterogeneidade estudada é de rótulo, não de domínio de entrada.
 - Não reporta custo de comunicação de forma sistemática.
- UniHAR: Towards a Universal Human Activity Recognition Model — Xu et al., 2023
 - Publicação: MobiCom
 - Tópicos: SSL Federado, HAR
 - Contribuições:
 - Competidor mais próximo: combina SSL e FL em HAR baseado em sensores.
 - Propõe pipeline de harmonização de dados heterogêneos entre usuários.
 - Avalia em múltiplos datasets públicos de HAR.
 - Limitações:
 - Usa uma única técnica de SSL — não compara famílias distintas (contrastiva vs. *augmentation-free*).
 - Mede que a federação é pior sob heterogeneidade, mas não isola a causa por meio de controles pareados.
 - Não compara pré-treino centralizado contra pré-treino federado.
- Spatio-temporal Heterogeneous Federated Learning for Time Series Classification (FedST / FedOST) — Wu et al., 2024
 - Publicação: ACM MM (e IEEE TMC, 2026)
 - Tópicos: Aprendizado Federado, Séries Temporais
 - Contribuições:
 - Trabalho mais próximo no uso de informação tempo-frequência em ambiente federado.



- Treinamento ortogonal multi-visão como mecanismo de personalização.
- Avaliação em classificação de séries temporais heterogêneas.
- Limitações:
 - É **supervisionado**: usa tempo-frequência como regularização, não como objetivo auto-supervisionado.
 - Mira personalização por cliente, não uma representação transferível comum.
 - Não mede custo de comunicação nem compara topologias de pré-treino.
- Federated Self-Supervised Learning of Multi-Sensor Representations for Embedded Intelligence — Saeed et al., 2021
 - Publicação: IEEE Internet of Things Journal
 - Tópicos: SSL Federado, Sensores
 - Contribuições:
 - Marco pioneiro de SSL federado sobre dados de sensores vestíveis.
 - Mostra viabilidade de pré-treino auto-supervisionado descentralizado em dispositivos com recursos limitados.
 - Limitações:
 - Técnica de SSL baseada em tarefas pretexto escaladas, anterior à geração contrastiva/augmentation-free atual.
 - Não caracteriza heterogeneidade de domínio de forma controlada.
 - Baselines limitados e protocolo de avaliação pouco detalhado.
- Rethinking the Representation in Federated Unsupervised Learning with Non-IID Data — Liao et al., 2024
 - Publicação: CVPR
 - Tópicos: SSL Federado
 - Contribuições:
 - Documenta que o colapso de representação é mais severo em SSL federado do que no centralizado — risco central do nosso Experimento 3.
 - Propõe diagnóstico do colapso baseado no espectro das representações.
 - Limitações:
 - Domínio de imagens; não valida em séries temporais.
 - Non-IID sintético (Dirichlet), não heterogeneidade de domínio real.
 - Não considera métodos *augmentation-free*.
- Label-Efficient Self-Supervised Federated Learning (masked vs. contrastive) — Yan et al., 2023
 - Publicação: IEEE Transactions on Medical Imaging
 - Tópicos: SSL Federado
 - Contribuições:
 - Evidência direta de que a **família** de SSL importa sob agregação federada — hipótese que o nosso desenho testa para séries temporais.
 - Comparação controlada entre objetivo mascarado e contrastivo no mesmo pipeline federado.
 - Limitações:
 - Imagens médicas; não há transposição imediata para sinais inerciais.
 - Não inclui métodos *augmentation-free*.

- Não mede custo de comunicação.

2.5. Limitações identificadas e lacuna de pesquisa

Consolidando as limitações listadas acima, o levantamento identificou quatro lacunas que sustentam a proposta:

- **Nenhuma das duas técnicas selecionadas foi avaliada em ambiente federado.** A verificação de ineditismo de LFR e TF-C sob FL foi conduzida por quatro vias independentes — busca estruturada em bases, *snowballing* de citações via Semantic Scholar, *snowballing* via OpenAlex e consultas dirigidas — sem ocorrência. Registra-se como limitação metodológica que o levantamento se baseou em títulos, resumos e trechos indexados, não em leitura integral de todo o conjunto; a confirmação final está prevista para a semana da submissão.
- **A literatura de SSL federado federa uma técnica por trabalho.** Não há comparação controlada entre famílias de SSL (contrastiva vs. *augmentation-free*) sob o mesmo pipeline federado em séries temporais. Yan et al. mostram que a família importa, mas em imagens médicas e sem métodos *augmentation-free*.
- **A heterogeneidade avaliada é quase sempre sintética.** Predomina partição por Dirichlet ou por rótulo; a heterogeneidade de domínio real — sensores em posições distintas do corpo, dispositivos e protocolos de coleta diferentes — raramente é isolada como variável controlada.
- **O custo de comunicação do pré-treino auto-supervisionado não é medido.** Nenhum dos trabalhos revisados quantifica o volume transmitido na fase de pré-treino, embora essa seja precisamente a diferença de custo entre pré-treino centralizado e federado — a comparação central do plano.

Essas quatro lacunas definem o posicionamento da proposta e orientaram o desenho experimental descrito nas seções seguintes.

3. Experimento 1 — implementação e validação centralizada do SSL

3.1. Dados

Todos os experimentos usam a `standardized_view` do benchmark DAGHAR, composta por seis datasets de HAR baseados em sensores inerciais de smartphone. Cada amostra é uma janela de 6 canais (acelerômetro e giroscópio em x, y, z) por 60 passos de tempo. A tabela abaixo resume a composição medida diretamente dos arquivos:

Dataset	Posição no corpo	Taxa orig.	Classes	Janelas (treino)
KuHar	cintura (waist bag)	100 Hz	6	1.392
MotionSense	bolso (pocket)	50 Hz	6	3.558
RealWorld_thigh	coxa (thigh)	50 Hz	6	10.338
RealWorld_waist	cintura	50 Hz	6	10.332



Dataset	Posição no corpo	Taxa orig.	Classes	Janelas (treino)
UCI	cintura (waist bag)	50 Hz	5 (sem Run)	2.420
WISDM	bolso (pocket)	20 Hz	4 (Sit/Stand/Walk/Run)	8.748
Total	—	—	—	36.788

Tabela 1. Composição dos seis datasets do DAGHAR na visão padronizada. As classes padrão são {0 Sit, 1 Stand, 2 Walk, 3 Stair-up, 4 Stair-down, 5 Run}; UCI e WISDM não possuem todas elas. Valores medidos em 01/07/2026.

Duas observações relevantes para o desenho. Primeiro, os seis datasets se agrupam em **dois grupos cinemáticos** segundo a posição do sensor — cintura {KuHar, UCI, RealWorld_waist} e perna/bolso {MotionSense, WISDM, RealWorld_thigh} — e essa é a principal fonte de heterogeneidade de domínio da coleção. Segundo, os *splits* de treino, validação e teste são **disjuntos por usuário** nos seis datasets, o que permitirá particionar o treino por usuário nos cenários federados sem vazamento na avaliação.

3.2. Encoders

Foram considerados os três encoders previstos no plano, todos reusados do benchmark de referência para garantir comparabilidade célula a célula:

- **ResNet-SE-5** — ResNet 1D de 5 blocos com módulos *Squeeze-and-Excitation*; dimensão de saída 64.
- **CNN-PFF** — CNN com *parallel feature fusion*; dimensão de saída 768.
- **BiGRU** — GRU bidirecional (hidden 100, 1 camada) seguida de projeção linear; dimensão de saída 320.

3.3. Protocolo do Experimento 1

O experimento segue o desenho previsto no plano: **pré-treino auto-supervisionado sobre o corpus agregado** dos seis datasets, seguido de avaliação das representações em cada dataset individualmente.

Pré-treino. As duas técnicas (LFR e TF-C) foram pré-treinadas sobre o corpus combined, formado pela união dos *splits* de treino e validação dos seis datasets — **42.632 janelas, sem qualquer uso de rótulo** (36.788 de treino e 5.844 de validação). O LFR foi treinado por 600 épocas de *trainer* (equivalentes a 100 épocas efetivas de backbone, dada a alternância a cada 6 épocas) e o TF-C por 100 épocas, ambos sem *early stopping* e retendo o último estado, conforme o benchmark.

Avaliação das representações. Sobre cada backbone pré-treinado, uma cabeça de classificação MLP [enc, 128, 6] é treinada no *split* de treino rotulado de cada dataset, em dois protocolos:

- **linear readout** — backbone congelado (*requires_grad=False*), apenas a cabeça é treinável. É o protocolo que mede diretamente a qualidade da representação aprendida.
- **full fine-tuning** — backbone e cabeça treináveis. Serve de referência superior e indica quanto a representação ainda se beneficia de adaptação.



Cada combinação foi avaliada em quatro regimes de rótulos (1, 10 e 100 amostras por classe, e o *split* de treino completo) e replicada com **4 sementes** (0–3). A grade completa do Experimento 1 soma **3 encoders × 6 datasets × 4 sementes × 2 protocolos × 4 regimes = 576 células por técnica**, sem valores faltantes. Todas as métricas são acurácia e F1-macro sobre o *split* de teste, nunca visto no pré-treino nem no ajuste.

Convenção de leitura das tabelas: os valores são médias sobre os 3 encoders e o $\pm$ é o desvio-padrão entre as 4 sementes (média por semente, depois dispersão entre elas).

3.4. Resultado principal: qualidade das representações por linear readout

A Tabela 2 apresenta o resultado central do Experimento 1 — a qualidade das representações aprendidas, medida por linear readout em cada dataset, com o backbone congelado e o *split* de treino completo.

Dataset	LFR — acc	LFR — F1-macro	TF-C — acc	TF-C — F1-macro
KuHar	0,562 $\pm$ 0,047	0,491 $\pm$ 0,035	0,642 $\pm$ 0,029	0,609 $\pm$ 0,031
MotionSense	0,776 $\pm$ 0,013	0,769 $\pm$ 0,022	0,757 $\pm$ 0,007	0,752 $\pm$ 0,007
RealWorld_thigh	0,629 $\pm$ 0,005	0,635 $\pm$ 0,004	0,655 $\pm$ 0,019	0,657 $\pm$ 0,019
RealWorld_waist	0,705 $\pm$ 0,008	0,701 $\pm$ 0,007	0,683 $\pm$ 0,016	0,686 $\pm$ 0,016
UCI	0,821 $\pm$ 0,005	0,793 $\pm$ 0,003	0,752 $\pm$ 0,014	0,738 $\pm$ 0,012
WISDM	0,811 $\pm$ 0,003	0,807 $\pm$ 0,003	0,826 $\pm$ 0,004	0,821 $\pm$ 0,005
Média	0,717 $\pm$ 0,008	0,699 $\pm$ 0,007	0,719 $\pm$ 0,007	0,711 $\pm$ 0,007

Tabela 2. Linear readout in-domain com backbone pré-treinado no corpus agregado combined, regime de rótulos completo. Média sobre 3 encoders × 4 sementes; $\pm$ = desvio-padrão entre sementes.




Figura 1. Acurácia do linear readout por dataset. As barras de erro são o desvio-padrão entre as 4 sementes. Nenhuma das duas técnicas domina: o LFR vence em 3 datasets e o TF-C nos outros 3.

Três leituras. **Primeira: as duas técnicas produzem representações linearmente separáveis e de qualidade equivalente na média** (0,717 vs. 0,719 de acurácia). Com o

backbone completamente congelado, uma única camada sobre as features recupera cerca de 72% de acurácia média em seis domínios — o que confirma que ambos os pré-treinos aprenderam estrutura relevante para a tarefa, e não ruído.

Segunda: a equivalência na média esconde perfis distintos por dataset. O LFR é superior em MotionSense (+0,019), RealWorld_waist (+0,022) e sobretudo UCI (+0,069); o TF-C é superior em KuHar (+0,080), RealWorld_thigh (+0,026) e WISDM (+0,015). Não há dominância de uma técnica sobre a outra, o que é consistente com a hipótese do plano de que as duas famílias — contrastiva e *augmentation-free* — capturam propriedades diferentes do sinal e justifica mantê-las ambas nos cenários federados.

Terceira: o KuHar é o caso mais difícil para as duas técnicas (0,562 e 0,642, os menores valores da tabela, com a maior dispersão entre sementes). O dataset combina a menor quantidade de janelas de treino (1.392), o sensor menos rigidamente acoplado ao corpo (*waist bag* frouxo) e a maior heterogeneidade interna medida. Este comportamento é registrado desde já como limitação a ser considerada nos cenários federados, onde o KuHar tende a ser o cliente mais problemático.

3.5. Linear readout versus fine-tuning completo

A comparação entre os dois protocolos separa o que já está na representação do que ainda depende de adaptação ao domínio:

Técnica	Protocolo	Acurácia	F1-macro
LFR	linear readout	0,717 ± 0,008	0,699 ± 0,007
LFR	full fine-tuning	0,759 ± 0,013	0,734 ± 0,017
TF-C	linear readout	0,719 ± 0,007	0,711 ± 0,007
TF-C	full fine-tuning	0,852 ± 0,004	0,848 ± 0,003

Tabela 3. Linear readout vs. fine-tuning completo, média sobre os 6 datasets in-domain, regime completo. Média sobre 3 encoders × 4 sementes; ± = desvio-padrão entre sementes.

O achado relevante está na **diferença entre os ganhos de adaptação**: descongelar o backbone rende ao LFR +0,042 de acurácia, e ao TF-C **+0,133**. Ou seja, embora as duas representações sejam equivalentes quando avaliadas congeladas, a do TF-C tem margem de adaptação substancialmente maior. Cabe registrar, na interpretação desse valor, que o backbone composto do TF-C possui de 2,2 a 4,0 vezes mais parâmetros que o encoder isolado usado pelo LFR — característica constitutiva do método, herdada do trabalho original, e não uma escolha de dimensionamento deste trabalho. Essa diferença de tamanho tem consequência direta sobre o custo de comunicação nos cenários federados e será reportada explicitamente ao lado da acurácia nos meses 2 e 3.

3.6. Comportamento por encoder

Encoder	LFR — acc	LFR — F1-macro	TF-C — acc	TF-C — F1-macro
ResNet-SE-5	0,679 ± 0,005	0,659 ± 0,006	0,694 ± 0,006	0,685 ± 0,005

Encoder	LFR — acc	LFR — F1-macro	TF-C — acc	TF-C — F1-macro
CNN-PFF	0,718 ± 0,029	0,698 ± 0,027	0,793 ± 0,010	0,785 ± 0,011
BiGRU	0,755 ± 0,003	0,741 ± 0,004	0,671 ± 0,021	0,662 ± 0,022

Tabela 4. Linear readout por encoder, média sobre os 6 datasets, regime completo. Média sobre 4 sementes; ± = desvio-padrão entre sementes.




Figura 2. Interação encoder × técnica. A ordenação dos encoders se inverte conforme a técnica: o BiGRU é o melhor encoder sob LFR e o pior sob TF-C.

A interação entre técnica e encoder é marcada: o **BiGRU é o melhor encoder para o LFR** (0,755) e o **pior para o TF-C** (0,671), enquanto o **CNN-PFF é o melhor para o TF-C** (0,793). A amplitude entre encoders — 0,076 no LFR e 0,122 no TF-C — é uma ordem de grandeza maior que a dispersão entre sementes, de modo que a inversão não é atribuível a ruído. A implicação metodológica para os meses seguintes é que **encoder e técnica de SSL não podem ser variados de forma independente**: reportar uma técnica com um único encoder produziria conclusão dependente dessa escolha. Os cenários federados manterão, portanto, a grade cruzada técnica × encoder.

3.7. Comportamento sob escassez de rótulos

Rótulos por classe	LFR — linear	TF-C — linear	LFR — fine-tune	TF-C — fine-tune
1	0,308 ± 0,043	0,279 ± 0,019	0,395 ± 0,052	0,418 ± 0,036
10	0,404 ± 0,033	0,560 ± 0,008	0,570 ± 0,017	0,710 ± 0,012
100	0,608 ± 0,014	0,703 ± 0,006	0,712 ± 0,006	0,826 ± 0,007
Completo	0,717 ± 0,008	0,719 ± 0,007	0,759 ± 0,013	0,852 ± 0,004

Tabela 5. Acurácia in-domain por regime de rótulos, média sobre os 6 datasets. Média sobre 3 encoders × 4 sementes; ± = desvio-padrão entre sementes.

Comportamento sob escassez de rótulos — média in-domain sobre os 6 datasets




Figura 3. Acurácia in-domain em função do orçamento de rótulos, por protocolo. A faixa sombreada é o desvio-padrão entre as 4 sementes. A vantagem do TF-C se concentra nos regimes intermediários (10 e 100 amostras por classe) e desaparece, sob linear readout, no regime completo.

O regime de rótulos é onde as duas técnicas mais se separam. Com 10 e 100 amostras por classe, o **TF-C mantém vantagem consistente** sobre o LFR nos dois protocolos (+0,156 e +0,095 no linear readout; +0,140 e +0,114 no fine-tuning), diferenças muito superiores à dispersão entre sementes. Com uma única amostra por classe, ambas as técnicas degradam para a faixa de 0,28–0,42 e a comparação deixa de ser informativa.

3.8. Referência de desempenho centralizada

Para estabelecer a referência prevista no plano, os mesmos três encoders foram treinados de forma inteiramente supervisionada, do zero, em cada dataset — sem qualquer pré-treino. A comparação abaixo usa fine-tuning completo e o regime de rótulos completo, e o Δ é **pareado por semente**:

Dataset	Supervisionado	LFR	Δ LFR	TF-C	Δ TF-C
KuHar	0,645	0,547	−0,098	0,799	+0,154
MotionSense	0,830	0,846	+0,016	0,924	+0,094
RealWorld_thigh	0,690	0,680	−0,010	0,773	+0,082
RealWorld_waist	0,707	0,715	+0,008	0,768	+0,061
UCI	0,898	0,911	+0,013	0,951	+0,053
WISDM	0,820	0,855	+0,035	0,895	+0,076
Média	0,765 ± 0,005	0,759 ± 0,013	−0,006 ± 0,015	0,852 ± 0,004	+0,087 ± 0,005

Tabela 6. Referência centralizada: SSL pré-treinado no corpus agregado vs. treino supervisionado do zero no dataset, ambos com fine-tuning completo e regime de rótulos completo. Δ pareado por semente (72 pares por técnica); $\pm$ = desvio-padrão entre sementes.




Figura 4. Ganho de acurácia do pré-treino auto-supervisionado no corpus agregado sobre o treino supervisionado do zero, por dataset. Valores acima de zero indicam vantagem do pré-treino. O TF-C é positivo nos seis datasets; o LFR oscila em torno de zero, com o déficit concentrado no KuHar.

O TF-C supera o treino supervisionado do zero nos seis datasets, com ganho médio de $+0,087 \pm 0,005$ — efeito cerca de dezessete vezes maior que a dispersão entre sementes. O ganho é maior justamente onde há menos dados rotulados no alvo (KuHar, +0,154) e menor onde o dataset já é fácil isoladamente (UCI, +0,053). Esse é o resultado que sustenta a premissa do plano: **agregar dados não rotulados de múltiplos domínios no pré-treino compra desempenho**, e é exatamente essa agregação que o Aprendizado Federado precisa realizar sem centralizar os dados.

O LFR empata com o supervisionado ($-0,006 \pm 0,015$, efeito dentro do ruído), vencendo em quatro dos seis datasets. O déficit residual concentra-se no KuHar ($-0,098$), já identificado como o caso difícil na Seção 3.4. Registra-se a medição sem emitir veredito sobre o método: os dois braços não são pareados em orçamento de supervisão, uma vez que o braço auto-supervisionado não consome nenhum rótulo na fase de pré-treino.

3.9. Verificação da correção das implementações

O segundo objetivo do Experimento 1 é verificar que as implementações estão corretas. Três procedimentos foram executados:

- **Conformidade de configuração com o benchmark de referência.** Auditoria item a item das configurações de pré-treino (LFR e TF-C) e de *downstream* (linear readout e fine-tuning) contra os arquivos oficiais do benchmark: otimizador, taxa de aprendizado, tamanho de batch, número de épocas, política de *early stopping*, arquitetura da cabeça de classificação e configuração dos backbones. Os 14 itens materiais conferem; os desvios existentes são deliberados e estão listados na Seção 5.2.
- **Gate quantitativo contra os resultados publicados.** As células in-domain da nossa reprodução foram comparadas aos valores publicados pelo benchmark, resultando em viés de +0,4 a +2,4 pontos percentuais e erro absoluto médio de 1,7 a 2,5 pontos

percentuais — dentro da variação que o próprio benchmark apresenta entre re-execuções da mesma célula.

- **Revisão sistemática de código.** Leitura integral do código experimental e das classes da biblioteca envolvidas, procurando especificamente por vazamento de teste, vazamento de estado entre células da grade, contaminação de cache e erros de contagem de épocas efetivas. Nenhum defeito que invalide resultados foi encontrado. Verificou-se, em particular, que o *early stopping* monitora a perda de validação da fonte e que os conjuntos de teste entram apenas na avaliação final; que a cabeça de classificação é reconstruída a cada célula; e que a alternância do LFR de fato produz 100 épocas efetivas de backbone a partir de 600 épocas de *trainer*.

Conclui-se que as implementações centralizadas de LFR e TF-C estão corretas e que os números desta seção são utilizáveis como referência para os cenários federados.

4. Hiperparâmetros e protocolo de avaliação para os cenários federados

4.1. Hiperparâmetros consolidados

Os hiperparâmetros abaixo foram fixados a partir do benchmark de referência e validados pelo Experimento 1. **Eles serão mantidos sem alteração nos cenários federados dos meses 2 e 3**, de modo que qualquer diferença medida seja atribuível à topologia de treinamento e não a reconfiguração.

Fase	Item	Valor adotado
Pré-treino LFR	Otimizador	Adam, lr 3e-4, weight decay 3e-4, betas (0,9; 0,99)
	Projetores / preditores	6 alvos selecionados por DPP; size 60
	Alternância	5 épocas de preditor a cada ciclo
	Épocas	600 de trainer (= 100 efetivas de backbone), sem early stopping
	Batch	64 (drop_last = False)
Pré-treino TF-C	Otimizador	Adam, lr 3e-4, weight decay 3e-4, betas (0,9; 0,99)
	Perda	NT-Xent-poly, temperatura 0,2, cosseno; consistência $\lambda = 0,2$
	Backbone	Codificadores gêmeos tempo/frequência, 128 dimensões cada
	Épocas	100, sem early stopping
	Batch	64 (drop_last = True)
Downstream	Cabeça	MLP [enc, 128, 6] (TF-C: [256, 128, 6])
	Otimizador	Adam, lr 1e-4 nos dois protocolos
	Épocas / seleção	100, early stopping com paciência 50 em val_loss
	Batch	64
	Regimes de rótulos	1, 10 e 100 amostras por classe, e treino completo

Fase	Item	Valor adotado
Geral	Sementes	4 (0–3)
	Métricas	Acurácia e F1-macro

Tabela 7. Hiperparâmetros consolidados após o Experimento 1, a serem mantidos nos cenários federados.

4.2. Desvios deliberados em relação ao benchmark de referência

Cinco desvios foram adotados conscientemente e são registrados aqui para constar da seção de método do artigo:

- **Corpus de pré-treino.** Usamos os *splits* de treino e validação da visão padronizada; o benchmark usa visões não balanceadas de outra família. Justificativa: é o mesmo corpus dos nossos baselines supervisionados e dos cenários federados, o que mantém as comparações internas limpas. É o único desvio material, e os gates da Seção 3.9 mostram que a replicação permanece fiel apesar dele. Adicionalmente, pré-treinamos sobre o corpus agregado combined, que não existe no benchmark.
- **Semente da subamostragem em regime de poucos rótulos.** O benchmark fixa um subconjunto único; nós re-sorteamos por semente de execução. O nosso desenho captura a variância de amostragem do regime (4 subconjuntos $\times$ 4 inicializações), o que é estatisticamente mais informativo — ao custo de desvios-padrão maiores nos regimes de 1 e 10 amostras por classe.
- **Seleção do melhor estado em memória** em vez de gravação em disco, no *downstream*. Matematicamente idêntico; evita I/O.
- **Métricas calculadas via scikit-learn** em vez de torchmetrics. Definições idênticas.
- **Modo determinístico sem `cudnn.benchmark`.** Afeta velocidade e reprodutibilidade, não a estatística.

4.3. Protocolo de avaliação e limitação conhecida

O protocolo de avaliação adotado — e a ser mantido nos cenários federados — é o seguinte: o conjunto de treino do domínio-alvo é subamostrado conforme o regime de rótulos; a cabeça (linear readout) ou o modelo completo (fine-tuning) é treinada por até 100 épocas com *early stopping* de paciência 50 sobre a perda de validação; o estado de menor perda de validação é restaurado; e a avaliação final ocorre uma única vez sobre o *split* de teste.

A auditoria identificou uma **limitação conhecida deste protocolo**, que se registra explicitamente. Nos regimes de poucos rótulos, a subamostragem se aplica **apenas ao conjunto de treino**: a seleção de época continua usando o *split* de validação completo. Em um caso extremo — 1 amostra por classe no RealWorld_thigh — isso significa 6 janelas de treino contra 1.792 janelas usadas para selecionar o modelo. O conjunto que escolhe o modelo é, portanto, cerca de 300 vezes maior que o que o treina, e os números reportados nos regimes de 1, 10 e 100 amostras por classe são, nessa medida, otimistas.



Este comportamento **não é um desvio nosso**: é a semântica do *framework* utilizado e do benchmark que estamos replicando, que aplicam a subamostragem somente ao treino. Trata-se, porém, de um viés bem documentado na literatura de avaliação semi-supervisionada (Oliver et al., 2018, Seção 2.3), e alguns dos trabalhos originais das técnicas adotam protocolos distintos — o TF-C, por exemplo, escala o conjunto de validação com o orçamento de rótulos.

Decisão adotada: manter o protocolo como está, por fidelidade ao benchmark e para preservar a comparabilidade célula a célula dos nossos números com os publicados, **declarando explicitamente o protocolo e a limitação** na seção de método, em vez de deixá-los implícitos. A revisão desta decisão está prevista para antes da entrada do eixo de poucos rótulos nos cenários federados, onde o problema se agrava por o orçamento de rótulos passar a ser por cliente.

4.4. Justificativa das escolhas metodológicas para os experimentos federados

Os resultados do Experimento 1 sustentam quatro decisões de desenho para os meses 2 e 3:

- **Manter as duas técnicas de SSL.** A Tabela 2 mostra desempenho equivalente na média, mas com perfis complementares por dataset, e a Tabela 5 mostra separação clara sob escassez de rótulos. Descartar uma das técnicas nesta altura eliminaria justamente a comparação entre famílias — contrastiva e *augmentation-free* — que a revisão de literatura identificou como lacuna (Seção 2.5).
- **Manter a grade cruzada técnica × encoder.** A inversão de ordenação entre BiGRU e CNN-PFF conforme a técnica (Seção 3.6) demonstra que reportar uma técnica com um único encoder produz conclusão dependente dessa escolha. A grade federada preservará os três encoders.
- **Fixar o agregador em FedAvg.** Para atribuir o efeito medido à representação aprendida, e não ao agregador, é necessário manter o agregador constante entre os braços comparados. FedAvg é ainda o agregador de referência da literatura revisada (Bloco A), o que torna os resultados diretamente comparáveis. Variantes sensíveis a heterogeneidade de features, como FedBN, ficam previstas como ablação e não como configuração base.
- **Reportar custo de comunicação ao lado da acurácia.** A Seção 3.5 mostra que o backbone composto do TF-C tem de 2,2 a 4,0 vezes mais parâmetros que o encoder isolado usado pelo LFR. Como esse volume é transmitido a cada rodada, comparar as duas técnicas apenas por acurácia omitiria uma diferença de custo de primeira ordem. A revisão de literatura (Seção 2.5) registrou que nenhum dos trabalhos revisados mede o custo de comunicação da fase de pré-treino — razão adicional para incorporá-lo como métrica de primeira classe.

Com a referência centralizada estabelecida, os hiperparâmetros fixados e o protocolo de avaliação declarado, o Experimento 2 — pré-treino auto-supervisionado centralizado seguido de federação, comparado ao baseline federado supervisionado — pode ser executado sem reconfiguração, garantindo que a diferença medida seja atribuível à estratégia de inicialização.

5. Conclusões

As quatro atividades previstas para o primeiro mês foram concluídas.

A **revisão de literatura** cobriu os dois eixos do plano e identificou quatro lacunas que sustentam a proposta: LFR e TF-C nunca foram avaliadas em ambiente federado; a literatura de SSL federado federa uma técnica por trabalho, sem comparação entre famílias; a heterogeneidade avaliada é quase sempre sintética, e não de domínio real; e o custo de comunicação do pré-treino auto-supervisionado não é medido por nenhum dos trabalhos revisados.

A **implementação e validação centralizada** das duas técnicas foi concluída e verificada por três procedimentos independentes — conformidade de configuração, gate quantitativo contra os resultados publicados do benchmark (viés de +0,4 a +2,4 pontos percentuais) e revisão sistemática de código. A grade do Experimento 1 está completa e sem valores faltantes.

A **avaliação por linear readout** mostrou que as duas técnicas produzem representações linearmente separáveis e equivalentes na média (0,717 e 0,719 de acurácia), mas com perfis complementares por dataset e por encoder. Sob fine-tuning completo, o pré-treino auto-supervisionado sobre o corpus agregado supera o treino supervisionado do zero em $+0,087 \pm 0,005$ no caso do TF-C, vencendo nos seis datasets, e empata no caso do LFR — resultado que estabelece a referência centralizada e sustenta a premissa do plano de que agregar dados não rotulados de múltiplos domínios no pré-treino compra desempenho.

A **definição dos hiperparâmetros e do protocolo de avaliação** foi consolidada, com os cinco desvios deliberados em relação ao benchmark registrados e uma limitação conhecida do protocolo de poucos rótulos declarada explicitamente, junto da decisão de mantê-la por fidelidade ao benchmark replicado.

O primeiro mês entrega, portanto, a referência de desempenho centralizada, as implementações validadas e a configuração experimental congelada — as três condições necessárias para que o Experimento 2, previsto para o segundo mês, meça o efeito da topologia de treinamento e não o de reconfiguração.